

大模型應用匯報

金融科技部 產品研發組
2024年9月12日




一、大模型項目背景

內部聊天機器人Bell

- 現況：Bell於2018推出，是產研組自主研發的內部聊天機器人，使用傳統的聊天機器人技術，現提供日常IT問題查詢、帳戶解鎖、聯絡電話查詢等功能
- 未來目標：近年大模型及生成式AI等技術發展迅速，適合用於聊天機器人上，產研組計劃先在Bell上加入生成式AI的應用，推進我行人工智能的發展，同時為後續推出手機銀行聊天機器人做好準備

項目推進情況



二、可行的應用場景

編號	需求	用例	簡介
1	現有功能	IT在線支援	支援現時Chatbot的IT在線支援問題，包括解鎖帳戶、查詢聯絡電話等保留現有功能並同時增加其他常見問題，例如：電郵系統、金山軟件WPS相關問題等
2	新功能	翻譯及文法檢查	提供繁體中文、簡體中文、英文等常用語言翻譯提供文法檢查，分析文本中的語法錯誤，例如：句子結構、流暢性等，並向用戶提供建議句子提供基本繁簡體轉換、異體字的修改(臺->台，并->並等)
3	新功能	文字摘要	用戶輸入一段文本，由系統提供滿足字數限制的文字摘要視乎用戶需求，支援段落、點列式等不同形式的顯示
4	新功能	文檔編寫	用戶輸入文檔要求或提供參考的文檔（如：舊版本文檔），系統自動生成一段文本可用於編寫內聯網公告、產品條款、新聞稿、會議紀錄等文檔
5	新功能	編寫程式	用戶輸入程式碼，系統輔助進行程式編碼（如：修正程式錯誤）用戶輸入程式碼的條件（如：程式語言、用途等），系統自動生成程式碼或轉換程式編碼語言支援Java、SQL、Python、Node.js、Javascript、VBA等程式語言
6	新功能	規章搜尋	用戶輸入關鍵字/規章內容，由系統搜尋後，向用戶提供相關規章的連結
7	新功能	表格搜尋	用戶輸入所需服務，系統向用戶提供相關服務的申請途徑

三、總行AI實驗室

階段建設成果

平台建设

截圖取自總行人工智能建設項目匯報



三、總行AI實驗室

阶段建设成果

机制建设

从无到有

AI实验室搭建

提供多能力开发工具，实现
算力资源统筹管理，简化建
模用数流程

初步形成 AI模型研发规范

形成配套系统及流程支撑

需求准入

资源评估

模型开发

特征加工

模型质量监控

模型试投产

模型上线监控

模型成效跟踪

截圖取自總行人工智能建設項目匯報

团队

通过与外脑合作及知识转移，逐步摆脱数据和模型开发对厂商的依赖，自主掌握数据开发、算法优化及模型运维

算力

已有大数据集群共4864核CPU、33.7T内存、2.8P存储空间，GPU有108张英伟达A100、16张英伟达V100s、64张昇腾，当前有35个课题正在进行开发。

数据

已有完善的数据同步通道及相应审核机制，已审批并同步集市和数据湖的库表共800张，包含对公、零售、风险等多个条线的业务数据

三、總行AI實驗室

项目建设规划

大模型平台架构图

截圖取自總行人工智能建設項目匯報



四、大模型能力比較

中文大模型基準測評

- 目的：為獨立第三方AGI的評測機構，主要提供中文可用的通用大模型的一個評測標準
- 評測數據集：理科（計算、邏輯推理及代碼）、文科（知識百科語言理解、長文本、角色扮演、生成與創作等）、精確（模型遵循指令的能力，要求模型嚴格按照指令進行回覆的能力）
- 結果摘要：總行所使用的訊飛星火大模型與現時可免費使用的ChatGPT(GPT 3.5大模型)能力相約

大模型	機構	種類	推出日期	總分	理科得分	文科得分	精確得分
GPT-4o	OpenAI	私人	2024年5月	81	81	76	85
Qwen2-72B-Instruct	阿里巴巴	開源	2024年6月	77	76	76	79
Claude-3.5-Sonnet-200k	Anthropic	私人	2024年6月	77	75	72	84
Baichuan4	百川智能	私人	2024年5月	72	71	74	70
Llama-3-70B-Instruct	Meta	開源	2024年4月	69	68	67	72
文心一言4.0-8K-Latest	百度	私人	2024年6月	69	74	73	60
訊飛星火V4.0	科大訊飛	私人	2024年6月	67	71	70	60
GPT-3.5 (ChatGPT)	OpenAI	私人	2024年1月	64	64	69	59

*評分取自中文大模型基準測評2024年上半年報告

四、大模型能力比較

应用能力

藍色：内地大模型 橙色：國外大模型

实用主义者


卓越领导者

潜力探索者

技术领跑者

基础能力

*评分取自中文大模型基准测评2024年上半年报告



CUHK Industrial Project 24-25

1. Project Expectation

- Expectation: Compare the ability and strength of various open-source LLMs (e.g. chinese proficiency, accuracy, processing time, etc)
- Implement one or multiple prototype(s) for bankwide processes by leveraging RAG and LLM

2. Project Delivery

- Delivery: Report and prototype
- Suggested use cases: The prototype should be focusing on the document searching and FAQ as the major use cases
- Data set: HKMA Supervisory Policy Manual (in both Chinese and English)
- <https://www.hkma.gov.hk/chi/regulatory-resources/regulatory-guides/supervisory-policy-manual/>

3. Project Resources

- Hardware: Provide by CUHK (Cloud/on-permises environment)
- Suggested model: The LLM should have the proficiency to handle the enquires in Traditional Chinese, Simplified Chinese and English (e.g. LLaMA3, Qwen2, etc)



謝謝

始於1908 · 您的財富管理銀行